

LAPORAN PROJECT
PENGOLAHAN CITRA DIGITAL
S1 SAINS DATA - UNIVERSITAS NEGERI SURABAYA

IDENTITAS PROYEK	
Judul	Klasifikasi Aksara Jawa Da Ta Sa Wa La Menggunakan Convolutional Neural Network (CNN)
Topik	Handwriting classification: untuk da ta sa wa la
Identitas Penyusun	1. Luthfiana Syakira Eka Ramadani (24031554071) 2. Aida Zahira (24031554106) 3. Fauziah Roikhana Wardah (24031554162)
Kelas	2024 E

1. PENDAHULUAN

1.1 Latar Belakang

A. Latar Belakang

Aksara Jawa merupakan salah satu warisan budaya Indonesia yang berasal dari suku Jawa dengan populasi terbesar di Indonesia. Aksara dikenal dengan Hanacaraka, Carakan, atau Dentawyanjana yang terdiri dari 20 huruf dasar yaitu *ha-na-ca-ra-ka-da-ta-sa-wa-la-ma-ga-ba-tha-nga-pa-dha-ja-ya-nya*. Aksara Jawa digunakan sekitar abad ke-15 hingga pertengahan abad ke-20 untuk penulisan sastra maupun keperluan keseharian masyarakat Jawa[1]. Nilai budaya dan historis terkait penggunaan aksara Jawa di kalangan masyarakat saat ini semakin jarang dan ketertarikan generasi muda untuk mempelajarinya sangat minim[2].

Berbagai upaya dilakukan untuk melestarikan aksara Jawa agar tidak punah. Salah satu upaya yang bersifat kultural adalah penerapan aksara Jawa pada papan nama jalan, palang sebagai petunjuk lokasi di Daerah Istimewa Yogyakarta sebagai media pelestarian yang diletakkan di ruang publik[3]. Di sisi pendidikan, pengembangan media pembelajaran berbasis edukasi aksara Jawa terbukti efektif meningkatkan pemahaman siswa dengan validasi ahli materi mencapai 80% dan ahli media 96% [4]. Namun, pendekatan konvensional memiliki keterbatasan jangkauan dan efisiensi sehingga diperlukan pendekatan berbasis teknologi informasi yang lebih luas dan terstruktur.

Perkembangan teknologi kecerdasan buatan membuka peluang besar untuk mengembangkan sistem pengenalan aksara Jawa secara otomatis. Sri Sultan Hamengkubuwono X menegaskan bahwa literasi aksara Jawa harus berjalan seiring dengan pemanfaatan teknologi informasi dan komunikasi[1]. Salah satu pendekatan yang telah diteliti adalah metode *Deep Learning* menggunakan *Convolutional Neural Network* (CNN). Ilham & Rochmawati (2020) mengembangkan sistem transliterasi aksara Jawa tulisan tangan ke tulisan Latin menggunakan kombinasi metode CNN untuk klasifikasi[2]. Hasil penelitian memperoleh akurasi segmentasi 90% dan akurasi klasifikasi CNN sebesar 99,62% pada data pembelajaran, akurasi pada tahap pengujian dengan citra tulisan mencapai 80%. Di sisi lain, Hamzah & Pamungkas (2021) menggunakan metode Learning Vector Quantization dan Euclidean Distance untuk klasifikasi aksara Jawa tulisan tangan pada lima kelas karakter (Ha, Na, ca, Ra, Ka) dan memperoleh akurasi tertinggi 66,66% pada akasara Ra[5]. Hal ini

menunjukkan bahwa faktor kecerahan, ketebalan garis, dan warna tulisan berpengaruh signifikan terhadap performa klasifikasi.

Berdasarkan kajian sebelumnya, terdapat celah yaitu belum adanya studi yang berfokus pada lima karakter aksara Jawa Da, Ta, Sa, Wa, La yang memiliki kemiripan visual tinggi satu sama lain. Kemiripan bentuk antar karakter berpotensi menimbulkan ambiguitas dalam proses klasifikasi dan menjadi tantangan dalam pengenalan pola.

B. Rumusan Masalah

Dengan demikian, rumusan permasalahan dalam penelitian ini adalah:

1. Bagaimana membangun sistem klasifikasi yang mampu membedakan lima karakter aksara Jawa (Da, Ta, Sa, Wa, La) menggunakan metode pengolahan citra digital?
2. Seberapa tinggi akurasi yang dapat dicapai oleh sistem pada data yang telah disediakan?

1.2 Pendekatan pemecahan masalah

Dalam pendekatan pemecahan masalah pada penelitian dilakukan empat proses utama yang saling terhubung dalam membangun sistem klasifikasi aksara Jawa berbasis CNN. Proses diawali dengan akuisisi dataset, dilanjutkan dengan preprocessing data, pembangunan model, hingga evaluasi performa sistem. Pada tahap awal, dataset Hanacaraka diunduh menggunakan kagglehub dari platform kaggle. Dari total 20 kelas aksara Jawa yang tersedia, penelitian difokuskan untuk pengujian pada lima kelas aksara, yaitu da, ta, sa, wa, dan la. Seluruh dataset kemudian dimuat menggunakan OpenCV dalam format BGR sebagai dasar untuk proses pengolahan selanjutnya.

Setelah dataset berhasil dimuat, proses dilanjutkan ke tahap preprocessing data. Pada tahap ini dilakukan untuk meningkatkan kualitas data citra sebelum digunakan dalam pelatihan model, sehingga sistem dapat membedakan karakter aksara Jawa dengan lebih baik. Dalam penelitian ini, dirancang lima skenario eksperimen preprocessing untuk mengetahui pengaruh masing-masing teknik terhadap performa klasifikasi. Eksperimen terdiri dari Baseline (resize dan normalisasi), exp1_otsu (penambahan binarisasi Otsu), exp2_median_otsu (noise removal median sebelum otsu), exp3_full (noise removal median, Otsu thresholding dengan operasi morfologi closing), dan exp4_skeleton (skeletonization untuk mereduksi ketebalan stroke, dengan menggunakan noise removal media, otsu thresholding, morfologi closing, dan skeleton). Pipeline preprocessing mengacu pada pendekatan Ilham & Rochmawati yang mencakup konversi grayscale, binarisasi, dan normalisasi citra pada pengenalan aksara Jawa tulisan tangan[2]. Seluruh data citra kemudian diseragamkan ke ukuran 64×64 piksel dan dinormalisasi ke rentang nilai [0,1].

Tahap berikutnya adalah pembangunan model CNN sebagai inti dari sistem klasifikasi. Model CNN dipilih karena memiliki kemampuan mengekstraksi fitur dan melakukan klasifikasi citra secara terintegrasi dalam satu arsitektur, sebagaimana diterapkan pada penelitian pengenalan aksara Jawa sebelumnya[1], [2]. Arsitektur yang digunakan terdiri atas tiga blok konvolusi dengan 32, 64, dan 128 filter yang masing-masing diikuti oleh MaxPooling 2×2 . pada bagian klasifikasi, digunakan lapisan Dense sebanyak 256 neuron yang diikuti oleh output Softmax untuk mengenali lima kelas aksara. Lapisan Dropout dengan nilai 0.5 diterapkan setelah lapisan Dense untuk menonaktifkan secara acak 50% neuron selama proses

pelatihan. Penerapan dropout pada lapisan Dense merupakan pendekatan umum yang digunakan untuk mencegah overfitting pada model CNN, sehingga model mampu melakukan generalisasi dengan baik pada data yang belum pernah dilihat sebelumnya[6].

Dataset dibagi menggunakan stratified split menjadi 80% data latih, 10% data validasi, dan 10% data uji. Untuk meningkatkan variasi data latih, diterapkan augmentasi berupa rotasi hingga 10°, pergeseran horizontal dan vertikal sebesar 10%, serta zoom sebesar 10%. Kombinasi preprocessing dan arsitektur CNN tersebut menjadi dasar dalam membangun sistem klasifikasi aksara Jawa pada penelitian ini.

Proses terakhir adalah evaluasi model untuk mengukur tingkat performa sistem yang dihasilkan. Setiap skenario preprocessing menghasilkan model yang dievaluasi secara terpisah menggunakan data uji dengan metrik accuracy, precision, recall, F1-Score per kelas, serta confusion matrix[2]. Perbandingan hasil dari kelima eksperimen dilakukan untuk menentukan skenario preprocessing dengan performa terbaik. Selain itu, hasil penelitian juga dibandingkan dengan pendekatan terdahulu, seperti metode LVQ dengan akurasi 66.66% [5] dan metode OCR berbasis LBP dengan rata-rata akurasi 89.4%[7], untuk mengetahui sejauh mana sistem yang dibangun mampu memberikan peningkatan performa.

2. Metodologi


2.1 Eksplorasi Dataset

Dataset yang digunakan dalam penelitian ini adalah dataset Hanacaraka yang diunduh secara publik melalui platform Kaggle ([Dataset Hanacaraka](#)). Dari dataset tersebut, dipilih lima kelas aksara Jawa yang menjadi fokus penelitian, yaitu *da*, *ta*, *sa*, *wa*, dan *la*. Kelima karakter ini dipilih karena memiliki kemiripan visual yang tinggi satu sama lain sehingga menjadi tantangan klasifikasi yang relevan.

Eksplorasi awal dilakukan dengan memuat seluruh gambar dari masing-masing subfolder kelas menggunakan fungsi `load_dataset`. Proses EDA mencakup analisis distribusi jumlah gambar per kelas, statistik ukuran gambar (tinggi dan lebar minimum, maksimum, serta rata-rata), serta visualisasi sampel gambar sebanyak 5 citra per kelas. Visualisasi dilakukan menggunakan diagram batang dan diagram lingkaran untuk memastikan tidak ada ketimpangan distribusi antar kelas yang dapat mempengaruhi performa model.

2.2 Langkah Penelitian

Penelitian dilakukan dengan beberapa tahapan yang terstruktur, mulai dari load data hingga evaluasi model.



Gambar 1. Pipeline

1. Akusisi Data

Dataset Hanacaraka diunduh secara publik dari platform Kaggle melalui kaggle hub. Dari 20 kelas aksara Jawa yang tersedia, penelitian ini difokuskan pada lima kelas, yaitu da, ta, sa, wa, dan la. Kelima karakter ini dipilih karena memiliki kemiripan visual yang tinggi sehingga merupakan tantangan klasifikasi yang relevan. Seluruh citra dibaca menggunakan OpenCV dalam format BGR dan disimpan bersama label kelasnya.

2. Eksplorasi Data Analisis (EDA)

Setelah dataset dimuat, dilakukan eksplorasi awal untuk memahami karakteristik data. Analisis mencakup distribusi jumlah citra per kelas menggunakan diagram batang dan diagram lingkaran, serta visualisasi sampel sebanyak 5 citra per kelas. Tahap ini bertujuan memastikan tidak terdapat ketidakseimbangan distribusi data yang dapat mempengaruhi performa model.

3. Preprocessing

Tahap preprocessing dilakukan untuk meningkatkan kualitas dan konsistensi citra sebelum digunakan pada proses pelatihan model CNN. Setiap teknik preprocessing diimplementasikan dalam fungsi terpisah sehingga dapat dikombinasikan sesuai kebutuhan pada masing-masing skenario eksperimen. Dalam penelitian ini digunakan lima skenario preprocessing, yaitu *baseline* yang hanya menerapkan resize dan normalisasi citra, *exp1_otsu* dengan penambahan metode binarisasi Otsu, *exp2_median_otsu* yang menambahkan proses noise removal menggunakan Median filter sebelum binarisasi Otsu, *exp3_full* yang menambahkan operasi morfologi closing setelah proses Median filter dan binarisasi Otsu, serta *exp4_skeleton* yang menambahkan proses skeletonization setelah seluruh tahapan preprocessing sebelumnya untuk mereduksi ketebalan stroke aksara. Setelah seluruh tahapan preprocessing dilakukan, setiap citra diseragamkan ke ukuran 64×64 piksel dan dinormalisasi ke rentang nilai [0,1] agar dapat digunakan secara optimal pada proses pelatihan model.

4. Pembagian Data dan Augmentasi

Dataset yang telah melalui tahap *preprocessing* dibagi menjadi tiga bagian, yaitu 80% data latih, 10% data validasi, 10% data uji dengan menggunakan metode *stratified split* untuk menjaga keseimbangan distribusi kelas.

Proses augmentasi hanya diterapkan pada data latih menggunakan *ImageDataGenerator*, sebesar 10%. Teknik *horizontal flip* tidak digunakan karena berpotensi mengubah makna karakter aksara secara semantis.

5. Pembangunan Model CNN

Pembangunan Model Convolutional Neural Network (CNN). Model CNN digunakan karena kemampuannya dalam mengekstraksi fitur serta melakukan klasifikasi citra secara otomatis dalam satu arsitektur terintegrasi, sehingga sesuai untuk pengenalan karakter tulisan tangan[2]. Penggunaan CNN dalam pengenalan aksara Jawa juga telah terbukti memberikan performa yang baik dengan akurasi mencapai sekitar 84% pada penelitian sebelumnya[1].

Arsitektur model terdiri dari tiga blok konvolusi, yaitu:

- Blok pertama dengan 32 filter,
- Blok kedua dengan 64 filter,
- Blok ketiga dengan 128 filter,

Masing-masing blok diikuti oleh lapisan *MaxPooling* berukuran 2×2 . Setelah proses ekstraksi fitur, dilakukan *flattening* yang diikuti oleh lapisan *Dense* dengan 256 neuron dan *Dropout* sebesar 0,5 untuk mengurangi risiko *overfitting*. Lapisan output menggunakan fungsi aktivasi *Softmax* untuk klasifikasi lima kelas.

Model dikompilasi menggunakan *optimizer* Adam dan fungsi *loss categorical_crossentropy*. Proses pelatihan dilakukan hingga maksimum 50 *epoch* dengan penerapan *Early Stopping* (*patience* = 10) berdasarkan nilai *validation loss*, serta *ModelCheckpoint* untuk menyimpan bobot model terbaik berdasarkan *validation accuracy*.

6. Evaluasi dan Komparasi Model

Evaluasi model dilakukan menggunakan data uji dengan metrik akurasi, presisi, *recall*, dan F1-score untuk setiap kelas, serta *confusion matrix* untuk menganalisis pola kesalahan klasifikasi antar karakter[2].

Selain itu, hasil penelitian ini dibandingkan dengan beberapa pendekatan sebelumnya seperti metode *Learning Vector Quantization* (LVQ) dengan akurasi 66,66%[5], serta metode *Optical Character Recognition* (OCR) berbasis *Template Matching* dan ekstraksi fitur *Local Binary Pattern* (LBP) yang mampu mencapai rata-rata akurasi 89,4%[7]. Perbandingan ini bertujuan untuk menilai peningkatan performa yang dicapai oleh pendekatan CNN dalam penelitian ini.

3. Hasil Analisis

1. Import Library

Pada tahap awal dilakukan import seluruh library yang digunakan dalam penelitian. Library OpenCV dimanfaatkan untuk membaca dan memproses citra, NumPy digunakan dalam operasi numerik berbasis array, dan Matplotlib digunakan untuk menghasilkan berbagai visualisasi data dan hasil pemodelan. Selain itu, beberapa modul dari scikit-learn digunakan untuk pembagian dataset serta perhitungan metrik evaluasi model.

Proses pembangunan dan pelatihan model CNN dilakukan menggunakan TensorFlow dan Keras sebagai framework utama. Pada tahap preprocessing, library *skimage.morphology* digunakan pada proses *skeletonization* untuk mereduksi ketebalan stroke aksara. Untuk memastikan hasil eksperimen dapat direproduksi secara konsisten, nilai seed ditetapkan sebesar 42 pada seluruh komponen yang melibatkan proses acak.

2. Load Dataset


Dataset Hanacaraka diunduh melalui kagglehub, kemudian diseleksi untuk diambil lima kelas aksara yang menjadi fokus penelitian, yaitu da, ta, sa, wa, dan la. Seluruh data citra dengan format .png, .jpg, dan .jpeg dibaca menggunakan OpenCV dari masing-masing subfolder kelas. File yang gagal terbaca secara otomatis dilewati agar tidak mengganggu tahapan pemrosesan berikutnya.

Sebanyak 391 data citra berhasil dimuat dari lima kelas aksara yang digunakan dalam penelitian. Jumlah data pada masing-masing kelas relatif seimbang, meskipun terdapat sedikit perbedaan akibat beberapa data citra tidak dapat dibaca oleh OpenCV. Perbedaan tersebut tidak signifikan dan selanjutnya dianalisis lebih lanjut pada tahap EDA untuk memastikan keseimbangan distribusi data antar kelas.

3. Exploratory Data Analysis (EDA)

EDA dilakukan untuk memahami karakteristik pada dataset awal. Analisis ini berfokus pada distribusi jumlah data citra per kelas serta tingkat keseimbangan data yang akan digunakan dalam proses pelatihan model.

Distribusi jumlah gambar tiap kelas divisualisasikan pada **gambar** dalam bentuk diagram batang dan diagram lingkaran.




Gambar 2 . Bar Chart & Pie Chart

Berdasarkan gambar 2, distribusi kelas terlihat cukup merata, menunjukkan bahwa rasio antara kelas dengan jumlah data paling banyak dan paling sedikit hanya sebesar 1,04x, jauh di bawah ambang batas ketidakseimbangan data sebesar 1,5x. Dataset dapat dikategorikan sebagai balanced dataset sehingga metrik accuracy dapat digunakan sebagai metrik evaluasi utama dalam penelitian ini.

Selain distribusi data, beberapa contoh dari data citra pada masing-masing kelas aksara juga ditampilkan pada **gambar** untuk memberikan gambaran visual mengenai karakteristik tulisan tangan pada dataset.

Sampel 5 Gambar per Kelas



Gambar 3. sampel 5 gambar tiap kelas

Gambar 3 menunjukkan bahwa tulisan tangan pada setiap kelas memiliki variasi yang cukup tinggi, baik dari segi ketebalan stroke, ukuran karakter, maupun posisi aksara di dalam frame gambar. Variasi tersebut menjadi tantangan tersendiri dalam proses klasifikasi dan menjadi alasan penting dilakukannya preprocessing sebelum data digunakan pada proses pelatihan model CNN.

4. Pre-Processing

Tahap preprocessing dilakukan untuk meningkatkan kualitas dan konsistensi citra sebelum digunakan dalam proses pelatihan model CNN. setiap teknik preprocessing diimplementasikan dalam fungsi terpisah sehingga dapat dikombinasikan sesuai kebutuhan masing-masing skenario eksperimen.

4.1 GrayScale

Citra asli yang diperoleh dari dataset memiliki tiga kanal warna dalam format BGR. oleh karena itu, melakukan konversi ke grayscale untuk menyederhanakan representasi citra menjadi satu kanal intensitas. Dengan menghilangkan informasi warna yang tidak relevan, model dapat lebih fokus pada pola bentuk dan struktur stroke aksara dibandingkan variasi warna pada citra.

Berikut ini perbandingan citra sebelum dan sesudah proses grayscale.



Gambar 4. Original vs. Grayscale

Berdasarkan Gambar 4, proses konversi grayscale berhasil mengubah citra berwarna menjadi representasi intensitas hitam-putih, sehingga pola aksara menjadi lebih sederhana dan mudah diproses pada tahapan berikutnya.

4.2 Noise Removal

Citra tulisan tangan umumnya mengandung noise berupa piksel-piksel acak yang dapat mengganggu proses binarisasi dan ekstraksi fitur. Untuk mengurangi gangguan tersebut, dilakukan pengujian terhadap tiga metode noise removal, yaitu Gaussian filter, Median filter, dan Bilateral filter.

Perbandingan hasil ketiga metode ditampilkan pada Gambar 5.




Gambar 5. Perbandingan tiga metode noise removal

Berdasarkan hasil output pada Gambar 5, metode Median filter dipilih sebagai teknik noise removal yang digunakan dalam eksperimen. Dibandingkan metode lainnya, Median filter mampu mengurangi noise dengan lebih baik tanpa menghilangkan detail penting pada tepi stroke aksara. Dengan demikian, struktur karakter tetap terjaga sehingga lebih sesuai untuk proses binarisasi dan klasifikasi pada tahap berikutnya.

4.3 Thresholding

Tahap thresholding atau binarisasi dilakukan untuk mengubah citra grayscale menjadi citra biner yang hanya memiliki dua nilai piksel, yaitu hitam sebagai latar belakang dan putih sebagai objek aksara. Proses ini bertujuan agar model lebih mudah mengenali struktur bentuk karakter tanpa terganggu variasi intensitas abu-abu pada citra.

Dalam penelitian ini, diuji tiga metode thresholding, yaitu Global Thresholding, Otsu Thresholding, dan Adaptive Thresholding. Perbandingan hasil dari ketiga metode tersebut ditampilkan pada gambar berikut.




Gambar 6. Perbandingan hasil Thresholding

Berdasarkan Gambar 6, metode Otsu menghasilkan pemisahan antara stroke aksara dan latar belakang yang lebih baik dibandingkan metode Global Thresholding. Hal ini karena nilai ambang pada metode Otsu ditentukan secara otomatis berdasarkan distribusi intensitas piksel citra, sehingga tidak memerlukan penentuan threshold secara manual.

4.4 Morfologi

Operasi morfologi diterapkan pada citra hasil thresholding dengan menggunakan structuring element berbentuk persegi. Terdapat empat operasi morfologi yang diterapkan dan dibandingkan, yaitu erosi, dilasi, opening dan closing. Hasil dari masing-masing operasi morfologi dapat dilihat pada gambar berikut.



Gambar 7. Perbandingan hasil Morfologi

Gambar 7 menunjukkan analisis hasil tabel sebagai berikut:

Tabel 1. Analisis Hasil Morfologi.


Operasi	Hasil Pengamatan
Biner	Citra menampilkan tulisan tangan dengan garis tipis yang masih terlihat jelas dan mempertahankan bentuk objek asli.
Erosi	Garis tulisan mengalami pengikisan yang sangat signifikan sehingga objek hampir menghilang seluruhnya.
Dilasi	Garis tulisan menjadi lebih tebal dan lebih jelas terlihat, karena area objek mengalami penambahan piksel.
Opening	Hasil serupa dengan erosi, noise halus berhasil dihilangkan dan garis tulisan terkikis karena didahului proses erosi.
Closing	garis tulisan tetap terjaga dengan ketebalan yang lebih stabil, serta beberapa celah kecil pada objek berhasil tertutup.

Berdasarkan hasil perbandingan visual tersebut, operasi closing menghasilkan citra yang paling optimal karena mampu mempertahankan bentuk tulisan tangan dengan baik sekaligus mengurangi noise dan menutup celah kecil pada objek. Dibandingkan operasi morfologi lainnya, hasil closing menunjukkan bentuk karakter yang lebih utuh dan jelas sehingga operasi ini dipilih untuk diterapkan pada pipeline berikutnya.

4.5 Skeletonization

Skeletonisasi dilakukan untuk mengekstrak kerangka utama objek citra tulisan tangan, sehingga menghasilkan representasi garis tipis satu piksel yang tetap mempertahankan bentuk dan topologi objek asli. Metode yang digunakan adalah algoritma skeletonisasi dari library skimage.morphology.

Proses skeletonisasi diterapkan pada citra biner hasil thresholding, dengan perbandingan tiga tahap yang dapat dilihat pada gambar berikut:



Gambar 8. Perbandingan hasil Skeletonisasi

Gambar 8 menunjukkan analisis hasil tabel sebagai berikut.

Tabel 2. Analisis Hasil Skeletonisasi

Tahap	Hasil Pengamatan
Grayscale	Citra tulisan tangan tampil dengan latar putih, garis tulisan terlihat dengan ketebalan bervariasi.

Biner	Citra dikonversi menjadi latar hitam dengan garis putih, ketebalan garis masih bervariasi mengikuti tekanan tulisan asli.
Skeleton	Garis tulisan menjadi seragam tipis satu piksel, namun struktur dan bentuk tulisan tetap terjaga dengan baik.

Hasil skeletonisasi menunjukkan bahwa struktur tulisan tangan berhasil disederhanakan tanpa kehilangan informasi bentuk yang signifikan. Hal ini penting karena CNN lebih fokus mempelajari pola bentuk dan struktur tulisan dibandingkan ketebalan garis.

4.6 Resize dan Normalisasi

Tahap resize dan normalisasi dilakukan dengan menggunakan fungsi `resize_normalize()` yang menggabungkan dua proses sekaligus. Kode implementasinya adalah sebagai berikut:

```
def resize_normalize(img):
    resized = cv2.resize(img, TARGET_SIZE, interpolation=
    return resized.astype(np.float32) / 255.0
```


Gambar 9. Fungsi Resize dan Normalisasi

Fungsi ini menerima input citra dengan ukuran bervariasi, kemudian melakukan dua proses.

Resize dilakukan menggunakan `cv2.resize` dengan target ukuran mengacu pada variabel `target_size` yang dikonfigurasi secara fleksibel sesuai kebutuhan eksperimen. Metode interpolasi yang digunakan adalah `cv2.inter_area`, yang dipilih karena optimal untuk proses pengecilan ukuran citra dengan cara merata-ratakan piksel pada area yang diciutkan sehingga menghasilkan citra yang lebih halus tanpa artefak. Penyeragaman ukuran ini diperlukan karena dataset tulisan tangan memiliki dimensi yang tidak konsisten, sedangkan model CNN mensyaratkan input dengan ukuran yang seragam. Normalisasi dilakukan dengan mengkonversi tipe data menjadi `float32` lalu membagi nilai piksel dengan 255.0. Normalisasi bertujuan untuk mempercepat konvergensi saat training dan menstabilkan proses gradient descent pada model CNN.

4.7 Pipeline dan Konfigurasi Eksperimen

Pipeline pre-processing disusun secara berurutan dan diterapkan secara konsisten pada seluruh dataset. Visualisasi pipeline untuk setiap aksara Jawa dapat dilihat pada gambar berikut.



Gambar 10. Tahapan Preprocessing Setiap Aksara Jawa
Pada gambar menunjukkan analisis hasil tabel sebagai berikut.

Tabel 3. Analisis Hasil Tahapan Preprocessing Setiap Aksara Jawa

Tahap	Metode	Fungsi
Original	-	Citra awal berupa tulisan tangan aksara jawa dengan latar belakang dan ketebalan garis yang masih bervariasi.
Grayscale	RGB ke Gray	Mengubah citra berwarna menjadi satu kanal intensitas sehingga proses pengolahan citra menjadi lebih sederhana tanpa memengaruhi bentuk aksara.
Noise Removal	Median Filter	Mengurangi noise halus pada citra dengan mempertahankan bentuk dan tepi utama tulisan tangan agar tidak terlalu kabur.
Thresholding	Otsu Thresholding	Memisahkan objek tulisan dari latar belakang menjadi citra biner secara otomatis sehingga bentuk aksara tampak lebih jelas.
Morfologi	Closing	Mempertahankan struktur tulisan sekaligus menutup celah pada garis kecil aksara, sehingga bentuk tulisan terlihat lebih utuh dan konsisten.
Skeleton	Skeletonization	Mereduksi ketebalan garis aksara menjadi representasi kerangka tanpa menghilangkan bentuk utama tulisan.

Dari hasil tersebut didapatkan pengamatan untuk setiap aksaranya yang tertuang dalam tabel berikut.

Tabel 4. Pengamatan per Aksara

Aksara	Catatan
Da	Pipeline preprocessing mampu mempertahankan bentuk utama aksara dengan baik hingga tahap skeletonization sehingga struktur karakter tetap terlihat jelas.
Ta	Detail garis dan lekukan aksara masih dapat dipertahankan pada hasil skeleton meskipun ketebalan stroke telah direduksi.
Sa	Bentuk aksara yang memiliki pola lengkung berhasil diproses dengan baik tanpa menghilangkan struktur utama karakter.
Wa	Garis lengkung pada aksara tetap dapat dibedakan dengan cukup jelas setelah melalui proses morfologi dan skeletonization.
La	Pipeline preprocessing berhasil melakukan binarisasi pada citra dengan latar belakang yang lebih terang sehingga bentuk aksara tetap dapat dipertahankan dengan baik.

Pipeline diterapkan secara seragam pada seluruh dataset sebelum masuk ke tahap split data dan training model CNN.

4.8 Split Data

Dataset dibagi menjadi tiga subset dengan proporsi sebagai tabel berikut.

Tabel 5. Split data

Subset	Proporsi	Jumlah Citra
Training	80%	313
Validasi	10%	39
Testing	10%	39
Total	100%	391

Pembagian dataset menjadi training, validasi, dan testing dilakukan untuk memastikan model dapat dilatih, dievaluasi, dan diuji secara objektif. Data training digunakan sebagai data utama untuk proses pembelajaran model dalam mengenali pola pada aksara Jawa. Pada tahap ini, model mempelajari karakteristik setiap kelas berdasarkan citra yang diberikan. Data validasi digunakan selama proses pelatihan untuk memantau performa model dan membantu menentukan parameter terbaik, seperti jumlah epoch atau pemilihan model dengan performa optimal. Selain itu, data validasi berfungsi untuk mendeteksi terjadinya overfitting, yaitu kondisi ketika model terlalu menghafal data training sehingga performanya menurun pada data baru.

Dan data testing digunakan pada tahap akhir untuk mengukur kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya. Evaluasi menggunakan data testing memberikan gambaran performa model secara lebih objektif dalam melakukan klasifikasi aksara Jawa. Pembagian dataset dilakukan secara stratified untuk memastikan distribusi setiap kelas tetap seimbang pada setiap subset. Dari total 391 citra yang terdiri dari 5 kelas,

sebanyak 313 citra digunakan untuk pelatihan model, 39 citra untuk validasi selama proses pelatihan model, dan 39 citra untuk pengujian akhir model.

4.9 Augmentasi Data Training


Augmentasi data diterapkan hanya pada data training untuk meningkatkan variasi data dan mencegah overfitting. Teknik augmentasi yang digunakan meliputi:

Tabel 6. Teknik Augmentasi

Teknik Augmentasi	Parameter
Rotasi	Sekitar 10°
Pergeseran Horizontal	10%
Pergeseran Vertikal	10%
Zoom	10%
Flip Horizontal	-
Flip Vertikal	-
Fill Mode	Nearest

Augmentasi diterapkan secara on-the-fly menggunakan image data generator, sehingga setiap epoch model menerima variasi citra yang berbeda secara acak tanpa menambah jumlah citra secara fisik. Data training tetap berjumlah 313 citra, namun dengan variasi transformasi yang berbeda di setiap epoch sehingga model lebih robust dan terhindar dari overfitting.

Contoh hasil augmentasi untuk setiap kelas ditunjukkan pada gambar berikut:



Gambar 11. Hasil Augmentasi per Kelas Aksara

Dari gambar tersebut terlihat bahwa setiap citra asli menghasilkan variasi augmentasi yang berbeda-beda melalui kombinasi rotasi kecil, pergeseran posisi, dan zoom namun tetap mempertahankan bentuk karakteristik masing-masing aksara Jawa. Dengan 5 varian augmentasi per citra, jumlah data training bertambah menjadi 6x lipat dari training original, sehingga model CNN memiliki kemampuan generalisasi lebih baik terhadap tulisan tangan aksara Jawa.

5. Arsitektur CNN

Model CNN dibangun menggunakan Tensorflow/keras dengan arsitektur sebagai berikut:

Tabel 7. Model CNN

No	Layer	Type	Output Shape	Aktivasi	Parameter
1	conv2d	Konvolusi	(None,64,64,32)	ReLU	320
2	max_pooling2d	Pooling	(None,32,32,32)	-	0
3	conv2d_1	Konvolusi	(None,32,32,64)	ReLU	18.496
4	max_pooling2d_1	Pooling	(None,16,16,64)	-	0
5	conv2d_2	Konvolusi	(None,16,16,128)	ReLU	73.856
6	max_pooling2d_2	Pooling	(None,8,8,128)	-	0
7	flatten	Flatten	(None,8192)	-	0
8	dense	Fully Connected	(None,256)	ReLU	2.097.408
9	dropout	Regularisasi	(None,256)	-	0
10	dense_1	Output	(None,5)	Softmax	1.285

Ringkasan Parameter:

- a. Total parameter : 2.191.365
- b. Trainable parameter : 2.191.365
- c. Non-trainable parameter : 0

Pemilihan arsitektur ini didasarkan pada kesederhanaan model, namun cukup dalam untuk menangkap fitur citra aksara Jawa. Tiga blok konvolusional dengan jumlah filter yang meningkat (32, 64, 128) memungkinkan model mempelajari fitur dari yang sederhana hingga kompleks, sementara lapisan dropout digunakan untuk mencegah overfitting selama pelatihan.

6. Training Early Stopping

Proses pelatihan model CNN dilakukan menggunakan fungsi `train_model()` yang menggabungkan augmentasi data secara *real-time* dengan dua mekanisme kontrol pelatihan, yaitu EarlyStopping dan ModelCheckpoint.

6.1 EarlyStopping

EarlyStopping digunakan untuk menghentikan proses pelatihan secara otomatis apabila nilai validation loss tidak menunjukkan perbaikan selama 10 epoch berturut-turut (`patience=10`). Parameter `restore best_weights=True` memastikan bahwa bobot model yang digunakan pada akhir pelatihan adalah bobot terbaik yang diperoleh selama training, bukan bobot pada epoch terakhir.

Mekanisme ini berperan penting dalam mencegah overfitting, yaitu kondisi di mana model terlalu menyesuaikan diri dengan data latih sehingga performa pada data baru menurun.

6.2 ModelCheckpoint

ModelCheckpoint digunakan untuk menyimpan model terbaik secara otomatis selama proses pelatihan berlangsung. Model disimpan berdasarkan nilai validation accuracy tertinggi yang dicapai pada setiap epoch. Dengan demikian, meskipun pelatihan berlanjut hingga epoch berikutnya, model terbaik tetap tersimpan dan dapat digunakan untuk evaluasi akhir.

6.3 Konfigurasi Pelatihan

Pada proses pelatihan model, diterapkan mekanisme *early stopping* dengan nilai *patience* sebesar 10 berdasarkan metrik *validation loss*. Teknik ini digunakan untuk menghentikan proses pelatihan secara otomatis ketika performa model pada data validasi tidak lagi mengalami peningkatan, sehingga dapat mengurangi risiko *overfitting*.



Gambar 12. Training Curve (Loss dan Accuracy)- exp1_otu

Berdasarkan Gambar 12, nilai training loss dan validation loss mengalami penurunan secara bertahap seiring bertambahnya epoch. Penurunan loss terlihat cukup signifikan pada awal pelatihan dan mulai stabil pada epoch akhir. Selain itu, kurva validation loss tidak menunjukkan kenaikan yang signifikan terhadap training loss sehingga model masih mampu melakukan generalisasi dengan baik.

Pada grafik accuracy, nilai training accuracy dan validation accuracy mengalami peningkatan secara konsisten hingga mencapai nilai di atas 90% pada epoch akhir. Meskipun terdapat sedikit fluktuasi pada validation accuracy, pola kurva secara umum menunjukkan bahwa model berhasil mempelajari pola data dengan baik tanpa indikasi overfitting yang berlebihan. Pola pelatihan yang serupa juga ditemukan pada eksperimen preprocessing lainnya, meskipun terdapat perbedaan pada tingkat stabilitas dan kecepatan konvergensi model di setiap skenario.

7. Evaluasi


Evaluasi model dilakukan pada data uji yang sepenuhnya terpisah dari proses pelatihan. Data uji terdiri dari 10% data total yang tidak pernah dilihat model selama proses training maupun validasi, sehingga hasil evaluasi mencerminkan kemampuan generalisasi model sesungguhnya.

7.1 Metrik Evaluasi

Evaluasi performa model menggunakan beberapa metrik, antara lain *accuracy*, *recall*, dan *F1-score* untuk setiap kelas aksara. Selain itu, *Confusion*

Matrix digunakan untuk memberikan gambaran yang lebih rinci mengenai kemampuan model dalam mengklasifikasikan setiap kelas aksara, sekaligus mengidentifikasi pola kesalahan yang terjadi antar kelas.

Gambar 13. *Confusion Matrix* - exp1_otu



Berdasarkan gambar 13, terlihat bahwa kelas *ta*, *sa* dan *wa* berhasil diklasifikasikan secara sempurna tanpa kesalahan dengan akurasi sempurna 100%. Kesalahan terjadi pada kelas *da* yang sebanyak 2 kali diprediksi sebagai *sa*, dan kelas *la* yang 1 kali diprediksi sebagai *sa*. Hal ini kemungkinan disebabkan adanya kemiripan visual antara aksara *da*, *la* dan *sa* pada citra hasil preprocessing.

8. Visualisasi Hasil Klasifikasi

Visualisasi hasil klasifikasi dilakukan menggunakan fungsi *visualize_predictions()* untuk menampilkan prediksi model pada beberapa sampel citra aksara Jawa. Setiap citra diberikan label prediksi beserta nilai *confidence* yang dihasilkan model. Warna hijau menunjukkan prediksi yang benar, sedangkan warna merah menunjukkan prediksi yang salah.



Gambar 14. Handwriting Classification - exp1_otu

Berdasarkan Gambar 14, model mampu mengklasifikasikan sebagian besar citra dengan tingkat *confidence* yang tinggi, terutama pada kelas da, ta, wa, dan la yang banyak memperoleh confidence di atas 90%. Hal ini menunjukkan bahwa preprocessing menggunakan *Otsu thresholding* mampu membantu model dalam mempertahankan bentuk utama aksara sehingga pola karakter lebih mudah dikenali.

Namun, masih terdapat beberapa kesalahan klasifikasi, terutama pada kelas sa. Beberapa citra aksara sa diprediksi sebagai da dengan confidence yang cukup tinggi. Kesalahan ini diduga disebabkan oleh kemiripan bentuk stroke antar aksara serta variasi tulisan tangan yang berbeda pada setiap penulis, seperti ketidakkonsistenan bentuk lengkungan, ukuran karakter, dan posisi tulisan pada citra. Selain itu, beberapa sampel tulisan terlihat memiliki stroke yang tipis dan kurang lengkap sehingga mempersulit model dalam membedakan karakter antar kelas.


9. Loop Komparasi

Loop komparasi dijalankan secara berurutan untuk kelima skenario eksperimen menggunakan fungsi `run_experiment()`. Setiap eksperimen menjalankan pipeline secara lengkap mulai dari *preprocessing*, *split data*, pembangunan model CNN, hingga evaluasi dan visualisasi hasil klasifikasi. *Seed* direset pada awal setiap eksperimen untuk memastikan konsistensi hasil antar skenario.

Tabel 8. Akurasi Seluruh Eksperimen

Eksperimen	Accuracy	Loss
exp4_skeleton	97,50%	0.0730

exp3_full	95,00%	0.2425
exp1_otsu	92,50%	0.1676
exp2_median_otsu	92,50%	0.2258
baseline	20,00%	1.6097



Gambar 15. Grafik Perbandingan Eksperimen

Berdasarkan tabel dan grafik perbandingan akurasi, skenario exp4_skeleton menghasilkan performa terbaik dengan akurasi 97,50% dan loss terendah sebesar 0.0730.. Skenario ini menggunakan pipeline preprocessing paling lengkap yang mencakup noise removal, binarisasi otsu, morfologi closing, hingga skeletonisasi. Hasil ini menunjukkan bahwa setiap penambahan tahapan preprocessing secara bertahap berkontribusi positif terhadap peningkatan akurasi model.

Penambahan skeletonisasi pada exp4_skeleton memberikan peningkatan signifikan dibandingkan exp3_full dengan akurasi 95,0%, karena proses skeletonisasi mereduksi variasi ketebalan garis menjadi representasi satu piksel sehingga model CNN lebih fokus mempelajari pola bentuk struktural aksara dibandingkan variasi ketebalan akibat perbedaan tekanan tulisan.

Skenario exp1_otsu dan exp2_median_otsu menghasilkan akurasi yang sama sebesar 92,50%, menunjukkan bahwa pada dataset ini penambahan noise removal median sebelum otsu tidak memberikan perbedaan akurasi yang signifikan, meskipun secara visual kualitas citra meningkat.

Sementara itu, skenario baseline menerapkan resize dan normalisasi tanpa preprocessing tambahan menghasilkan akurasi terendah sebesar 20,0% yang mendekati probabilitas klasifikasi acak pada 5 kelas. Hal ini membuktikan bahwa tahap preprocessing memiliki peranan yang sangat krusial dalam meningkatkan kualitas fitur citra untuk klasifikasi aksara Jawa tulisan tangan berbasis CNN.

Apabila dibandingkan dengan penelitian sebelumnya, hasil terbaik pada skenario exp4_skeleton dengan akurasi 97,5% menunjukkan performa yang lebih unggul. Dengan demikian, pendekatan CNN yang dikombinasikan dengan pipeline preprocessing terbukti mampu meningkatkan performa klasifikasi aksara Jawa tulisan tangan secara signifikan.

4. Kesimpulan dan Saran

4.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, metode *Convolutional Neural Network* (CNN) mampu digunakan dengan baik dalam proses klasifikasi aksara Jawa tulisan tangan pada lima kelas aksara, yaitu da, ta, sa, wa, dan la. Hasil pengujian menunjukkan bahwa skenario preprocessing memberikan pengaruh yang signifikan terhadap performa model klasifikasi. Skenario exp4_skeleton menghasilkan performa terbaik dengan akurasi sebesar 97,50% dan nilai loss sebesar 0,0730. Hasil tersebut menunjukkan bahwa kombinasi preprocessing berupa median filtering, Otsu thresholding, operasi morfologi closing, dan skeletonization mampu menghasilkan representasi bentuk aksara yang lebih optimal sehingga fitur penting dapat dikenali dengan lebih baik oleh model CNN.

Selain itu, skenario exp3_full juga menunjukkan performa yang sangat baik dengan akurasi sebesar 95,00% dan loss sebesar 0,2425. Penambahan operasi morfologi closing pada tahap preprocessing terbukti membantu mempertahankan struktur aksara dan memperjelas bentuk objek sebelum dilakukan proses klasifikasi. Sebaliknya, model baseline tanpa preprocessing khusus hanya memperoleh akurasi sebesar 20,00%, yang menunjukkan bahwa preprocessing memiliki peran penting dalam meningkatkan kualitas citra dan membantu proses ekstraksi fitur oleh CNN.

Secara keseluruhan, tahapan preprocessing yang diterapkan berhasil mempertegas bentuk objek aksara, mengurangi noise, serta meningkatkan konsistensi pola tulisan tangan sehingga lapisan konvolusi dapat mengekstraksi fitur secara lebih optimal. Kombinasi CNN dengan teknik *dropout* dan augmentasi data juga mampu membantu model dalam mengurangi risiko *overfitting* serta menghasilkan kemampuan generalisasi yang baik pada data pengujian.

4.2 Saran

Untuk pengembangan sistem klasifikasi aksara Jawa yang lebih mendalam dan komprehensif di masa mendatang, terdapat beberapa langkah perbaikan akademis dan teknis yang dapat dipertimbangkan oleh penelitian selanjutnya. Eksplorasi dataset sebaiknya diperluas secara signifikan tidak hanya terbatas pada lima kelas karakter, melainkan dikembangkan untuk mencakup seluruh 20 karakter dasar Hanacaraka secara utuh. Selain memperbanyak jumlah kelas, pengumpulan data juga harus melibatkan variasi gaya penulisan tangan (*handwriting styles*) yang lebih heterogen dari berbagai kelompok usia dan generasi agar model memiliki ketahanan yang tinggi saat diuji dengan data riil di lapangan.

Mengingat model CNN konvensional yang dibangun dari awal seringkali membutuhkan sumber daya komputasi yang besar dan waktu pelatihan yang lama, penelitian selanjutnya sangat disarankan untuk menerapkan metode *Transfer Learning*. Salah satu opsi terbaik adalah menggunakan arsitektur MobileNetV2 yang dirancang khusus untuk perangkat dengan komputasi terbatas namun tetap mampu mempertahankan efisiensi tinggi dan performa akurasi yang optimal dalam mengenali aksara Jawa[8].

Di samping optimalisasi pada arsitektur model, tahap preprocessing juga dapat ditingkatkan secara lebih kompleks guna menangani dokumen aksara Jawa yang memiliki latar belakang naskah kuno yang mulai pudar. Implementasi teknik deteksi tepi (*edge detection*) dan deteksi kontur secara cerdas menggunakan library OpenCV sangat disarankan karena terbukti efektif untuk mempertajam pemisahan objek

aksara utama dari latar belakangnya sebelum dimasukkan ke dalam arsitektur klasifikasi jaringan saraf[9].

Terakhir, agar hasil evaluasi model tidak hanya berhenti pada laporan metrik performa di atas kertas, model klasifikasi terbaik yang telah dihasilkan kelompok sebaiknya diintegrasikan ke dalam sebuah sistem aplikasi praktis berbasis website ataupun aplikasi *mobile*. Langkah implementasi nyata ini sangat krusial agar teknologi kecerdasan buatan ini dapat diakses dengan mudah oleh masyarakat luas dan digunakan sebagai media pembelajaran digital yang interaktif guna melestarikan warisan budaya aksara Jawa di era modern[10].

Daftar Pustaka

- [1] A. Jonathan dan I. Wasito, "Perancangan Aplikasi Pengenalan Aksara Jawa Digital Menggunakan Convolutional Neural Network dan Computer Vision," *Decode J. Pendidik. Teknol. Inf.*, vol. 3, no. 2, hlm. 364–377, Agu 2023, doi: 10.51454/decode.v3i2.209.
- [2] F. Ilham dan N. Rochmawati, "Transliterasi Aksara Jawa Tulisan Tangan ke Tulisan Latin Menggunakan CNN," *J. Inform. Comput. Sci. JINACS*, vol. 1, no. 04, hlm. 200–208, Jul 2020, doi: 10.26740/jinacs.v1n04.p200-208.
- [3] A. S. Kinanti dan S. Sulistyowati, "Penggunaan Aksara Swara dan Aksara Rekan pada Papan Nama Jalan dan Papan Petunjuk Lokasi di Daerah Istimewa Yogyakarta," *Sutasoma J. Sastra Jawa*, vol. 10, no. 2, hlm. 140–149, Nov 2022, doi: 10.15294/sutasoma.v10i2.61576.
- [4] F. I. Pratiwi dan S. Rofi'ah, "Pengembangan Kartu Edukasi Aksara Jawa Pada Pembelajaran Bahasa Jawa Di Madrasah Ibtidaiyah," *Jurnal TARBAWI*, vol. 14, no. 1, hlm. 28–38, Okt 2024.
- [5] S. Hamzah dan D. P. Pamungkas, "Pengenalan Tulisan Tangan Aksara Jawa Menggunakan Metode Learning Vector Quantization (LVQ) dan Euclidean Distance," 2021.
- [6] Olivia Harris dan Michael Andrews, "Effects and results of dropout layer in reducing overfitting with convolutional Neural Networks (CNN)," *World J. Adv. Eng. Technol. Sci.*, vol. 13, no. 2, hlm. 836–853, Des 2024, doi: 10.30574/wjaets.2024.13.2.0584.
- [7] Christy Atika Sari, Wellia Shinta Sari, dan Putri Mega Arum Wijayanti, "PENGARUH LINEAR BINARY PATTERN (LBP) DALAM PENGENALAN CITRA AKSARA JAWA BERBASIS OPTICAL CHARACTER RECOGNITION (OCR)," *Semin. Nas. Teknol. Dan Multidisiplin Ilmu SEMNASTEKMU*, vol. 2, no. 1, hlm. 23–30, Des 2022, doi: 10.51903/semnastekmu.v2i1.149.
- [8] A. A. Rahmawati dan I. A. Putri, "Rancang Bangun Klasifikasi Aksara Jawa Menggunakan Convolutional Neural Network Berbasis Website," vol. 3, 2023.
- [9] N. S. Arief, W. A. Putra, dan D. S. R. Pratama, "Implementasi Cnn Arsitektur Mobilenetv2 Untuk Klasifikasi Tulisan Aksara Jawa," vol. 3, 2024.
- [10] I. G. S. M. Diyasa dan R. Romadhon, "Klasifikasi Karakter Tulisan Aksara Jawa Menggunakan Algoritma Convolutional Neural Network," *Semin. Keinsinyuran Program Studi Program Profesi Ins.*, vol. 3, no. 1, Mei 2023, doi: 10.22219/skpsppi.v3i1.7720.

Lampiran

Google Colab Link :  Final Project_Kelompok 07_PCD.ipynb

Link Dataset : <https://www.kaggle.com/datasets/vzrengamani/hanacaraka>